Telco Müşteri Kaybı (Churn) Tahmini — Karar Ağaçları ile

IBM Telco Customer Churn veri seti · Python / scikit-learn · Kaynak: github.com/uturkmen24/IBM-telco-customer-churn-prediction-by-decision-trees

1. Problem

Telekomünikasyon sektöründe yeni müşteri kazanmak, mevcut müşteriyi elde tutmaktan belirgin biçimde daha pahalıdır. Bu nedenle aboneliğini iptal etmeye eğilimli müşterileri (**churn**) önceden belirlemek kritik bir iş problemidir. Proje; müşteri demografisi, hesap bilgileri ve hizmet aboneliklerini kullanarak **ikili sınıflandırma** (Churn: Yes / No) problemini çözer. Asıl hedef yalnızca yüksek doğruluk değil, karar vericilerin proaktif elde tutma aksiyonları (hedefli sözleşme yükseltme, indirim kampanyaları) alabilmesi için **açıklanabilir iş kuralları** üretmektir.

2. Veri Seti, Temizleme ve Keşifsel Analiz (EDA)

Veri: *IBM-Telco-Customer-Churn.csv* dosyası **7.043 satır** ve **21 özellik** içerir; satırlar müşteri profillerini, faturalama bilgilerini ve hizmet eklerini temsil eder. Hedef değişken **Churn** (Yes/No) sütunudur. **Sınıf dağılımı dengesizdir:** müşterilerin yaklaşık **%73,5'i kalmış**, **%26,5'i ayrılmıştır**.

Ön işleme adımları:

- **Gizli eksik değerler (TotalCharges):** *isnull().sum()* sıfır eksik gösterse de sütun sayısal yerine *object* tipindeydi. İnceleme, **tenure = 0 olan 11 yeni müşterinin** TotalCharges değerinin boşluk karakteri (" ") olduğunu ortaya çıkardı. Bu değerler sayısala çevrilip ilk fatura dönemini tamamlamadıkları için **0.0** ile doldurulduu.
- **Tanımlayıcı çıkarma:** *customerID* tahmin sinyali taşımadığı ve aşırı öğrenmeye yol açtığı için kaldırıldı.
- **Kanıta dayalı özellik seçimi:** EDA ve ağaç önemi kontrollerine göre etkisiz değişkenler elendi (örn. *gender*: churn oranları neredeyse aynı, %26,9 ve %26,1). Finansal, hizmet ve demografik boyutları kapsayan **8 özellik** seçildi: **Sayısal (3)** tenure, MonthlyCharges, TotalCharges; **Kategorik/ikili (5)** Contract, InternetService, TechSupport, OnlineSecurity, SeniorCitizen.

EDA bulguları (*groupby*, *crosstab* ve Matplotlib görselleştirmeleri ile):

Sözleşme türü	Churn oranı
Aylık (month-to-month)	**%42,7**
1 yıllık	%11,3
2 yıllık	%2,8

İnternet hizmeti	Churn oranı
Fiber optik	**%41,9**
DSL	%18,9
İnternet yok	%7,4

Grup	Ort. tenure	Ort. aylık ücret
Ayrılan	~18 ay	~74,4 $
Kalan	~37,6 ay	~61,3 $

Saçılım grafiği, ayrılan müşterilerin belirgin biçimde **düşük kıdem (<20 ay) ve yüksek aylık ücret (>70 $)** bölgesinde kümelendiğini gösterir. Sözleşme türü ve internet hizmeti tipi, churn davranışını en güçlü ayıran değişkenler olarak öne çıkar.

3. Model Seçimi ve Eğitim

Veri **%80 eğitim (5.634 örnek)** ve **%20 test (1.409 örnek)** olarak bölündü (*random_state=42*). Kategorik değişkenler sayısal temsillere (0, 1, 2) dönüştürüldü; uygun yerlerde sıralı yapı (örn. sözleşme süresi) korundu. Model: **DecisionTreeClassifier (max_depth=4)**. Seçim gerekçeleri:

- **Karma veri tipleri:** Sürekli finansal metrikleri (MonthlyCharges) ve kodlanmış kategorikleri (Contract) ölçeklemeye gerek duymadan işler.
- **Doğrusal olmayan etkileşimler:** Churn, koşullu kombinasyonlardan doğar (örn. yüksek aylık ücret VE aylık sözleşme); ağaç bunları hiyerarşik "eğer–ise" bölünmeleriyle yakalar.
- **Açıklanabilirlik (white-box):** *plot_tree* görselleştirmesi, kayıp riskini yönlendiren eşikleri açıkça gösterir: *Contract ≤ 0.5*, *InternetService ≤ 1.5*, *tenure ≤ 14.5*.

Mini uygulama: Not defterindeki *predict_churn()* fonksiyonu 8 müşteri parametresini *input()* ile alır, DataFrame'e çevirir ve *predict()* ile *predict_proba()* kullanır. Ham 0/1 yerine olasılık yüzdesiyle birlikte eyleme dönük iş önerisi üretir (örn. %78,40 olasılıkla churn grubunda; acil bağlılık/indirim kampanyası önerilir).

4. Sonuçlar (Test Kümesi)

Aşırı öğrenme kontrolü için model hem eğitim hem görülmemiş test verisinde değerlendirildi: **Eğitim doğruluğu %79,39**, **Test doğruluğu %79,70**. İki skorun neredeyse aynı olması, *max_depth=4* kısıtının ezberlemeyi engellediğini ve modelin genellenebilir örüntüler öğrendiğini gösterir.

Sınıf	Precision	Recall	F1	Destek
Kaldı (0)	0,83	0,91	0,87	1.036
Ayrıldı (1)	0,66	**0,49**	0,56	373
Genel doğruluk	–	–	**0,80**	1.409

Karışıklık matrisi	Tahmin: Kaldı	Tahmin: Ayrıldı
Gerçek: Kaldı	TN = 941	FP = 95
Gerçek: Ayrıldı	FN = 191	TP = 182

Model kalan müşterileri çok iyi tanır (recall 0,91) ancak ayrılan müşterilerin yaklaşık yarısını yakalayabilir (recall 0,49; 373 ayrılan müşteriden 182'si doğru tespit edildi, 191'i kaçırıldı).

5. Çıkarımlar, Sınırlılıklar ve Gelecek Çalışmalar

- **İş çıkarımı:** Churn riski en çok **aylık sözleşmeli** (%42,7), **fiber optik** (%41,9), **kısa kıdemli** ve **yüksek aylık ücretli** müşterilerde yoğunlaşır; 2 yıllık sözleşmede oran yalnızca %2,8'dir. Bu nedenle uzun dönem sözleşmeye geçiş ve hedefli indirim kampanyaları en mantıklı elde tutma kaldıraçlarıdır.
- **Model değeri:** Sığ ağaç (derinlik 4) hem genellenebilir (%79,39 / %79,70) hem de iş birimlerinin doğrudan okuyabileceği kurallar sunar. Churn oranı %26,5 olan dengesiz yapıda doğruluk tek başına yeterli ölçüt değildir; asıl zayıf nokta churn sınıfındaki düşük recall'dur.
- **Sınıf dengesizliği:** Ayrılanları daha iyi yakalamak için *class_weight='balanced'* veya **SMOTE** ile aşırı örnekleme planlanmaktadır.
- **Mikro yapraklar:** Ağaç görselleştirmesinde sağ alttaki iki yaprak yalnızca **5 ve 6 örnek** içerir (uzun sözleşmeli, yüksek ücretli müşteriler) ve istatistiksel olarak güvenilmezdir. *min_samples_leaf=20* kısıtı veya **Random Forest / XGBoost** gibi topluluk yöntemleri bu sorunu giderecektir.